La Concurrence Concepts de Langages de Programmation

Juan-Carlos Barros et Daniel Kessler

juin 2021

La Concurrence

- Introduction
- 2 Mémoire partagée : un problème critique
- Côté pratique
- Changement de paradigme
- Conclusion

Introduction

- Introduction
 - Définition de la concurrence
 - Le cerveau vs le CPU
 - Le système d'exploitation
- Mémoire partagée : un problème critique
- Côté pratique
- 4 Changement de paradigme
- Conclusion

Définition

La **concurrence** en informatique consiste en l'exécution de plusieurs **tâches** simultanément (pendant des périodes qui se chevauchent) plutôt que séquentiellement (l'une démarrant après la fin de l'autre).

Le **cerveau** est intrisèquement **concurrent**.

Le cerveau est intrisèquement concurrent.

traitement du stimulus visuel

Ce mot est rouge.

Ce mot est vert.

Le cerveau est intrisèquement concurrent.

- traitement du stimulus visuel
- traitement du stimulus auditif

Ce mot est rouge.

Ce mot est vert.

Le cerveau est intrisèquement concurrent.

- traitement du stimulus visuel
- traitement du stimulus auditif
- traitement de la syntaxe, grammaire puis sémantique

Ce mot est rouge.

Ce mot est vert.

Le cerveau est intrisèquement concurrent.

- traitement du stimulus visuel
- traitement du stimulus auditif
- traitement de la syntaxe, grammaire puis sémantique
- analyse du sens

Ce mot est rouge.

Ce mot est vert.

Le cerveau est intrisèquement concurrent.

- traitement du stimulus visuel
- traitement du stimulus auditif
- traitement de la syntaxe, grammaire puis sémantique
- analyse du sens
- comparaison avec les connaissances mémorisées

Ce mot est rouge.

Ce mot est vert.

Le cerveau est intrisèquement concurrent.

- traitement du stimulus visuel
- traitement du stimulus auditif
- traitement de la syntaxe, grammaire puis sémantique
- analyse du sens
- comparaison avec les connaissances mémorisées
- critique

Ce mot est rouge.

Ce mot est vert.

Le processeur est intrinsèquement séquentiel.

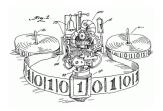
• Une instruction exécutée à la fois



- Une instruction exécutée à la fois
- Pourquoi chercher la concurrence?



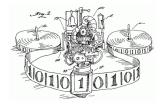
- Une instruction exécutée à la fois
- Pourquoi chercher la concurrence?
 - Interruptions I/O



- Une instruction exécutée à la fois
- Pourquoi chercher la concurrence?
 - Interruptions I/O
 - Exécuter plusieurs programmes "simultanément"



- Une instruction exécutée à la fois
- Pourquoi chercher la concurrence?
 - Interruptions I/O
 - Exécuter plusieurs programmes "simultanément"
 - Systèmes distribués





Le système d'exploitation est un "magicien".

• gestion des ressources séquentielles



- gestion des ressources séquentielles
- couches d'abstraction



- gestion des ressources séquentielles
- couches d'abstraction
- partage des ressources :
 - → l'ordonnanceur



- gestion des ressources séquentielles
- couches d'abstraction
- partage des ressources :
 - → l'ordonnanceur
 - gestion des priorités



- gestion des ressources séquentielles
- couches d'abstraction
- partage des ressources :
 - → l'ordonnanceur
 - gestion des priorités
 - commutation des contextes



Mémoire partagée : un problème critique

- Introduction
- Mémoire partagée : un problème critique
 - Les fondamentaux de la concurrence
 - Problèmes et solutions
- Côté pratique
- 4 Changement de paradigme
- Conclusion

Les fondamentaux de la concurrence

Comment se manifeste la concurrence ? (répartition des tâches)

- multiplicité des processus
- multiplicité des fils d'exécution (threads)

Comment communiquent les différents composants?

• via des ressources communes

Problèmes et solutions

Problèmes

- Situation de compétition
- Inversion de priorité
- Entrelacement
- Interblocage
- Famine
- etc.

Solutions

- Verrous
- L'Atomicité
- Les Moniteurs
- Les Sémaphores
- Futures et Promises
- Et d'autres paradigmes


Problème 1 : **interleaving** ("entrelacement")

Déterminisme ou indéterminisme?

- programme séquentiel : toujours déterministe
- programme concurrent : peut être déterministe
 - \rightarrow toutes les possibilités d'entrelacement doivent été prises en compte !
 - ightarrow prouver la validité d'un programme concurrent est particulièrement ardu !
- Si le résultat dépend de l'ordre d'exécution, le déterminisme est perdu

Problème 2 : race condition

Deux tâches pourraient tenter d'accéder à une même partie de leur mémoire partagée simultanément, ce qui dans la pratique pourra poser problème.



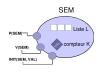
Solution 1 : verrou (lock)

Un verrou limite l'accès d'une ressource à une seule tâche.

- état fermé vs. état ouvert
- si le verrou est fermé, les tâches sont bloquées
- sinon, une tâche qui accède à la ressource ferme le verrou
- quand la tâche finit, elle ouvre le verrou

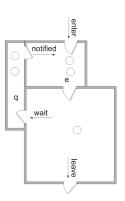
Solution 2 : **sémaphore** de Dijkstra

- Inventé pour l'OS "THE operating system"
- Compteur de tâches en attente de la ressource
- 3 primitives
 - Init(sem, max) définit nombres d'utilisateurs max
 - P(sem) pour accéder à la ressource
 - V(sem) pour quitter la ressource
- P(sem) bloque si max atteint, sinon incrémente le compteur
- V(sem) décrémente le compteur et notifie les tâches en attente
- cas particulier : sémaphore binaire ou mutex quand max=1.



Solution 3 : **moniteur** (Hoare / Brinch-Hansen)

- Inventé pour Equivalent Pascal et Solo operating system
- Verrou avec une ou plusieurs conditions
- Condition liée à file d'attente de processus voulant accéder à une ressource
- Équivalence avec sémaphores



Solution 3 : **moniteur** (Hoare / Brinch-Hansen)

- Inventé pour Equivalent Pascal et Solo operating system
- Verrou avec une ou plusieurs conditions
- Condition liée à file d'attente de processus voulant accéder à une ressource
- Équivalence avec sémaphores

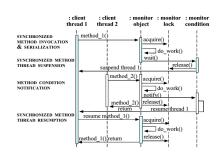


Fig. 3. Sequence diagram of the Monitor Object concurrency pattern [Schm00].

Solution 3 : **moniteur** (Hoare / Brinch-Hansen)

```
public class SynchronizedCounter {
  private int c = 0;
  public synchronized void increment() {
    C++;
  public synchronized void decrement() {
    c--;
  public synchronized int value() {
    return c;
```

Problème 3 : interblocage et famine

Verrous, etc. ⇒ nouveaux problèmes!...

- Deux tâches pourraient chacune verrouiller une ressource dont l'autre à besoin
 - $\rightarrow \text{interblocage}$
- Une tâche attend indéfiniment une ressouce bloquée
 - $\rightarrow \text{famine}$



Solution 4: Futures et Promises

Les **Futures** et **Promises** sont des abstractions de plus haut niveau que les verrous, sémaphores ou moniteurs.

Un Future/Promise est une valeur qui peut déjà être disponible, ou sinon, devrait devenir disponible plus tard.

La distinction entre les deux est floue et dépend du langage de programmation.

Si distinction il y a, le Future apparaît comme un objet "en lecture seule".


Côté pratique

- Introduction
- 2 Mémoire partagée : un problème critique
- 3 Côté pratique
 - Implémenation naïve
 - Thread/Process Pools
 - Tests de performance
- 4 Changement de paradigme
- Conclusion

Implémenation naïve d'un Future minimal en Python

```
class FutureNaif:
  """Future implémenté "à la main", avec thread privé."""
  def __init__(self, task):
      """Initialiser un Future."""
      self.done = False
      self.result = None
      self task = task
      # pas besoin de lock vu que le thread est créé
      # sur place et n'est référencé nulle part ailleurs
      self._thread = threading.Thread(target=self._target)
      self._thread.start()
 def _target(self):
      """Travail à effectuer par le thread dédié."""
      self.result = self._task()
      self.done = True
```

Thread/Process Pools et Executors



Futures en Python (avec **pooling**)

Comparaison de deux situations...

- Calcul intensif
- I/O avec latence

Futures en Python (avec pooling)

Comparaison de deux situations...

- Calcul intensif
- I/O avec latence

...en utilisant trois approches :

- séquentielle
- concurrente par threads (garantis non parallélisés)
- concurrente par process (garantis parallélisés)

Changement de paradigme

- Introduction
- 2 Mémoire partagée : un problème critique
- Côté pratique
- Changement de paradigme
 - Autres manières d'utiliser des futures
 - Les fondamentaux de la concurrence (2)
 - Modèle d'Acteurs de Hewitt
 - Autres approches
- 5 Conclusion

Future avec callback associé (exemple en Scala)

```
import scala.concurrent.Future
import scala.concurrent.ExecutionContext.Implicits.global
import scala.util.{Failure, Success}
object ScalaFuture extends App {
 val finiraPlusTard = Future {
    ... // tâche longue
  finiraPlusTard.onComplete {
    case Success(valeur) => traiterValeurDeRetour(valeur)
    case Failure(exception) => gererException(exception)
  Thread.sleep(2000) // "garder en vie" le runtime
```

pipelining de Promise (exemple en javascript)

```
function faireQuelqueChose() {
   // ...
     return new Promise (...)
faireQuelqueChose()
  .then(x => faireAutreChose(x))
  .then(x => faireUneTroisiemeChose(x))
  .then (x = > \{
       console.log("Résultat final reçu: ${x}");
  .catch (gererEchec);
```

Les fondamentaux de la concurrence (2)

Comment se manifeste la concurrence ? (répartition des tâches)

- multiplicité des fils d'exécution (threads)
- multiplicité des processus

Comment communiquent les différents composants?

via des ressources communes

Les fondamentaux de la concurrence (2)

Comment se manifeste la concurrence ? (répartition des tâches)

- multiplicité des fils d'exécution (threads)
- multiplicité des processus
- multiplicité des processeurs
- multiplicité des machines

Comment communiquent les différents composants?

via des ressources communes

Les fondamentaux de la concurrence (2)

Comment se manifeste la concurrence ? (répartition des tâches)

- multiplicité des fils d'exécution (threads)
- multiplicité des processus
- multiplicité des processeurs
- multiplicité des machines

Comment communiquent les différents composants?

- via des ressources communes
- de manière synchrone : transmission d'information directe
- de manière asynchrone : transmission d'information indirecte

Éviter la mémoire partagée?

- ullet La mémoire partagée était la source de la plupart des problèmes \Rightarrow
 - l'éviter ou la cacher dans une couche d'abstraction qui la gère de manière automatique et efficace
- Les communications ne devraient se faire que par messages ou événements
- Les messages ou événements ne devraient être constitué que de données immuables

Modèle d'Acteurs de Hewitt

Un acteur peut :

- Envoyer des messages à d'autres acteurs
- Créer d'autres acteurs
- Décider de son comportement à la prochaine réception de message

Modèle d'Acteurs en Erlang

Le langage **Erlang** exploite bien ce modèle.

```
-module (acteur) .
-export([start/0, alice/0]).
alice() ->
    receive
        hello ->
            io:format("Alice dit bonjour.~n", [])
    end.
start() ->
    Alice_PID = spawn(acteur, alice, []),
    Alice PID ! hello.
```

Plus récemment, le langage **Scala** utilise ce même modèle, à travers le "toolkit" **Akka**.

Du modèle d'Acteurs au π -calcul de Milner

Le modèle d'acteurs a influencé le π -calculus (algèbre de processus)

P, Q ::= x(y). P	Receive on channel x , bind the result to y , then run P
$\mid \overline{x}\langle y \rangle. P$	Send the value y over channel x , then run P
P Q	Run P and Q simultaneously
$\mid (\nu x)P$	Create a new channel x and run P
!P	Repeatedly spawn copies of P
0	Terminate the process

Du modèle d'Acteurs au π -calcul de Milner

Le modèle d'acteurs a influencé le π -calculus (algèbre de processus)

Now, the pure λ -calculus is built with just two kinds of thing: terms and variables. Can we achieve the same economy for a process calculus? Carl Hewitt, with his actors model, responded to this challenge long ago; he declared that a value, an operator on values, and a process should all be the same kind of thing: an actor.

(…)

So, in the spirit of Hewitt, our first step is to demand that all things denoted by terms or accessed by names—values, registers, operators, processes, objects—are all of the same kind of thing; they should all be processes.

Robin Milner, inventeur du π -calculus (*Turing Lecture* 1993)

Équivalence des paradigmes

Lauer et Needham on montré en 1978 que les modèles de concurrence basé sur processus et les modèles basés sur messages sont équivalents ("duaux").

ightarrow cf. On the duality of operating system structures H. Lauer, R. Needham 1978

- Programmation événementielle
 - utile pour les GUIs, mais difficile à analyser
 - "event loop"
 - "event handlers" (callbacks)

- Programmation événementielle
 - utile pour les GUIs, mais difficile à analyser
 - "event loop"
 - "event handlers" (callbacks)
- Transactions
 - idée inspirée des Bases de Donnée (langage SQL)
 - rendre "atomique" la section critique
 - idée exploitée par exemple dans le langage Clojure

- Programmation événementielle
 - utile pour les GUIs, mais difficile à analyser
 - "event loop"
 - "event handlers" (callbacks)
- Transactions
 - idée inspirée des Bases de Donnée (langage SQL)
 - rendre "atomique" la section critique
 - idée exploitée par exemple dans le langage Clojure
- Coroutines
 - coroutines : des routines concurrentes pouvant "vivre" dans le même thread
 - ▶ idée exploitée par exemple dans le langage Go ("goroutines")

- Programmation événementielle
 - utile pour les GUIs, mais difficile à analyser
 - "event loop"
 - "event handlers" (callbacks)
- Transactions
 - idée inspirée des Bases de Donnée (langage SQL)
 - rendre "atomique" la section critique
 - idée exploitée par exemple dans le langage Clojure
- Coroutines
 - coroutines : des routines concurrentes pouvant "vivre" dans le même thread
 - ▶ idée exploitée par exemple dans le langage Go ("goroutines")
- Réseaux de Petri (pour la modélisation)

Conclusion

- Introduction
- 2 Mémoire partagée : un problème critique
- Côté pratique
- 4 Changement de paradigme
- Conclusion

Conclusion : au-delà de la concurrence

Réseaux de neurone!